

Análisis de Datos de Tráfico Vehicular - Medellín 2019-2022

Proyecto Final Integrador
Nivel 2 - Análisis de Datos
Talento Tech

Línea de investigación: TIC - Movilidad Urbana Inteligente

Integrantes del equipo:

Fabio Mauricio Gallo Parra - Líder de proyecto / ETL / DB / Dashboard / Documentación

Fecha de entrega: Junio 2026

1. Introducción

La movilidad urbana es uno de los mayores desafíos de las ciudades modernas. Medellín, como epicentro económico del Valle de Aburrá, enfrenta una congestión vehicular creciente que afecta la calidad de vida de sus habitantes, la productividad económica y el medio ambiente.

Este proyecto se enmarca en la línea de investigación de Ciencia, Tecnología e Innovación (TIC) para la transformación productiva y la resolución de desafíos sociales, económicos y ambientales. Específicamente, aborda la problemática de la movilidad urbana mediante el análisis de datos abiertos de la Secretaría de Movilidad de Medellín (SMM), que registran el flujo vehicular en puntos estratégicos de la ciudad.

El objetivo es construir una solución integral que integre, procese, analice y visualice datos de tráfico vehicular para generar recomendaciones basadas en evidencia que permitan optimizar la movilidad, reducir la congestión y mejorar la seguridad vial en la ciudad.

2. Desarrollo del Proyecto

2.1 Problemática Identificada

Medellín cuenta con más de 19 millones de registros de tráfico vehicular entre 2019 y 2022, distribuidos en 48 archivos Excel mensuales. Sin embargo, estos datos se encontraban dispersos, sin integrar y sin herramientas que permitieran su análisis efectivo. La problemática abordada es: ¿cómo integrar, analizar y visualizar estos datos para generar información útil que apoye la toma de decisiones en materia de movilidad urbana?

2.2 Arquitectura de la Solución

La solución implementada sigue una arquitectura de tres capas:

1. Capa de Datos (ETL): Procesamiento de 48 archivos Excel (~2.4 GB) mediante scripts Python para estandarizar, limpiar y transformar los datos a formatos Parquet y CSV.
2. Capa de Almacenamiento: Base de datos MySQL con tres tablas (trafico, incidentes, zonas_criticas) que almacenan ~19.3 millones de registros de tráfico y 100,000 incidentes.
3. Capa de Visualización: Dashboard interactivo en Streamlit con 12+ visualizaciones que permiten explorar los datos desde múltiples perspectivas.

2.3 Base de Datos

Se diseñó una base de datos relacional en MySQL con el siguiente esquema:

- trafico (24 columnas): Almacena los registros de flujo vehicular con información de velocidad, intensidad, ocupación, ubicación (coordenadas convertidas a WGS84), comuna, corredor, y métricas derivadas como índice de congestión y período del día.
- incidentes (8 columnas): Contiene 100,000 registros de incidentes de tráfico (accidentes, congestiones, obras, etc.) con clasificación por gravedad.
- zonas_criticas (6 columnas): Vista materializada con el resumen por corredor y comuna para consultas rápidas.

Las consultas SQL avanzadas incluyen JOINS, subconsultas, funciones de ventana (ROW_NUMBER), agregaciones complejas y vistas materializadas.

2.4 Procesamiento ETL

Se implementaron dos pipelines ETL:

1. ETL Streaming (etl_streaming.py): Procesa los Excel en modo streaming con openpyxl, escribiendo directamente a CSV sin cargar todo en memoria. Ideal para máquinas con recursos limitados.
2. ETL Parquet (etl_trafico.py): Lee los Excel con pandas, aplica una muestra del 15%, normaliza columnas (nombres, tipos, fechas), calcula métricas derivadas (período del día, hora pico, índice de congestión) y exporta a Parquet con compresión Snappy.
3. Carga MySQL (load_mysql_wsl.py): Carga los datos a MySQL con checkpointing, modo streaming para archivos grandes, y mapeo inteligente de columnas que varían entre años.

2.5 Dashboard Interactivo

El dashboard en Streamlit (dashboard/app.py) ofrece:

- KPIs principales: Total registros, velocidad promedio, intensidad, índice de congestión.
- Filtros interactivos: Por año, corredor, período del día.
- Velocidad por hora: Gráfico de líneas con doble eje (velocidad + intensidad normalizada).
- Congestión por corredor: Top 15 corredores más congestionados.
- Heatmap hora-día: Intensidad vehicular en matriz hora vs día de semana.
- Evolución anual: Barras de velocidad vs línea de congestión.
- Estacionalidad mensual: Series por año para detectar patrones estacionales.
- Pronóstico lineal: Proyección 2023-2026 basada en tendencia histórica.
- Mapa interactivo: Puntos de medición con controles de color/tamaño, superposición de incidentes, y panel de detalle al hacer clic.
- Sección de incidentes: KPIs, gráficos por tipo/gravedad, mapa de incidentes.
- Comparativa tráfico vs incidentes: Scatter plot relacionando flujo vehicular con incidentes.

3. Resultados Obtenidos

Los principales hallazgos del análisis son:

1. Tendencia de congestión creciente: La velocidad promedio pasó de 27.8 km/h (2019) a 25.5 km/h (2022), mientras el índice de congestión subió de 21.7% a 27.4%.
2. Impacto de la pandemia (2020): Se observó una reducción artificial del flujo vehicular (-15% vs 2019) que disminuyó temporalmente la congestión.
3. Horas pico críticas: Entre 6-9 am y 5-8 pm la velocidad promedio cae por debajo de 20 km/h en los corredores más transitados.
4. Corredores críticos identificados: Se detectaron corredores específicos con índices de congestión superiores al 40%.
5. Incidentes: 100,000 registros con distribución equitativa entre tipos (congestión, accidentes, obras, etc.) y ~50% clasificados como críticos o graves.
6. Base de datos funcional: 19.3M registros de tráfico + 100K incidentes + 238 zonas críticas, consultables mediante SQL.

4. Conclusiones y Recomendaciones

Conclusiones:

- La integración de datos de múltiples fuentes (Excel, Parquet, MySQL) en un pipeline ETL robusto permitió unificar 19.3 millones de registros para su análisis.
- El dashboard interactivo facilita la exploración visual de patrones de movilidad y la identificación de puntos críticos de congestión.
- El cruce de datos de tráfico con incidentes revela correlaciones entre el flujo vehicular y la ocurrencia de eventos de tránsito.

Recomendaciones:

1. Priorizar intervenciones en los corredores con mayor índice de congestión (velocidad < 20 km/h).
2. Implementar sistemas de semafORIZACIÓN inteligente en horas pico (6-9 am y 5-8 pm).
3. Fortalecer la gestión de incidentes en los corredores con mayor volumen vehicular.
4. Actualizar el dataset con datos de 2023-2025 para mantener la vigencia del análisis.
5. Incorporar datos adicionales (clima, eventos masivos, obras viales) para enriquecer el modelo.
6. Migrar el pronóstico lineal a un modelo SARIMA o Prophet para capturar estacionalidad.

5. Roles del Equipo

A continuación se describen los roles y responsabilidades de cada miembro del equipo:

Fabio Mauricio Gallo Parra - Desarrollo Full Stack

Responsable de todas las fases del proyecto: diseño de la arquitectura ETL, implementación de los scripts de extracción y transformación (etl_streaming.py, etl_trafico.py), diseño del esquema relacional MySQL y carga masiva de datos (load_mysql_wsl.py), desarrollo de consultas SQL complejas (JOINS, subconsultas, ventanas), implementación del dashboard interactivo en Streamlit con visualizaciones Plotly, y elaboración de la documentación completa del proyecto.

--- Fin del Informe ---

Proyecto Integrador Talento Tech - Nivel 2 - Análisis de Datos

Medellín, Junio 2026